UNIVERSITÉ SORBONNE PARIS NORD

Projet : Analyse SQL & Python de la base ClassicModels

Par : GUEYE PALLA
M1 BIDABI 25/26

UNIVERSITÉ SORBONNE PARIS NORD

SOMMAIRE :

Introduction..... 3

1. Présentation générale de la base ClassicModels.....3

2. Partie 1 : Analyse exploratoire SQL.....3
2.1 Répartition géographique des clients..... 3
2.2 Répartition des commandes par statut.....4
2.3 Gamme de produits la plus rentable.....4
2.4 Top 5 des meilleurs clients..... 5
2.5 Top 10 des produits les plus vendus.....5

3. Partie 2 : Requêtes SQL avancées..... 5
3.1 Window Functions.....5
3.2 CTE récursif..... 6
3.3 Segmentation clients VIP..... 6
3.4 Analyse temporelle.....6
3.5 Rapport PIVOT..... 6

4. Partie 3 : Visualisations Python..... 6
4.1 Évolution mensuelle et trimestrielle du chiffre d'affaires.....6
4.2 Répartition du chiffre d'affaires par pays.....7
4.3 Comparaison du CA par gamme..... 7
4.4 Top 10 des produits les plus vendus (volume)..... 7
4.5 Analyse des stocks..... 8
4.6 Répartition du CA : Top 10 clients vs reste du monde.....8

5. Partie 4 : Analyses Python avancées.....8
5.1 Matrice de corrélation produits..... 8
5.2 Performance des employés.....9
5.3 Produits achetés ensemble.....9
5.4 Analyse RFM..... 9

6. Partie 5 : Recommandations stratégiques.....9

Conclusion.....10

Bibliographie.....11

Introduction

Dans un contexte économique où la donnée est devenue un levier stratégique majeur, la capacité d'une entreprise à analyser, comprendre et exploiter ses informations internes conditionne directement sa compétitivité. Le projet présenté dans ce rapport s'inscrit pleinement dans cette logique. Il vise à analyser en profondeur la base de données ClassicModels, un jeu de données commercial complet et structuré, afin d'en extraire des enseignements pertinents pour la prise de décision.

L'objectif n'est pas seulement de produire des statistiques descriptives, mais de proposer une lecture analytique et stratégique des données. Pour cela, plusieurs outils et méthodes ont été mobilisés : SQL pour l'exploration et les requêtes avancées, Python pour les visualisations et les analyses statistiques, et Jupyter Notebook pour structurer et documenter l'ensemble du processus.

Ce rapport adopte une démarche progressive : il commence par une exploration générale de la base, puis approfondit l'analyse à travers des requêtes complexes, avant de mobiliser des techniques avancées telles que la segmentation RFM, l'analyse de corrélation, l'étude de la saisonnalité, l'analyse du panier moyen ou encore l'évaluation de la performance commerciale. L'ensemble de ces éléments permet de dresser un portrait complet de l'activité de ClassicModels et d'identifier des axes d'amélioration concrets.

1. Présentation générale de la base ClassicModels

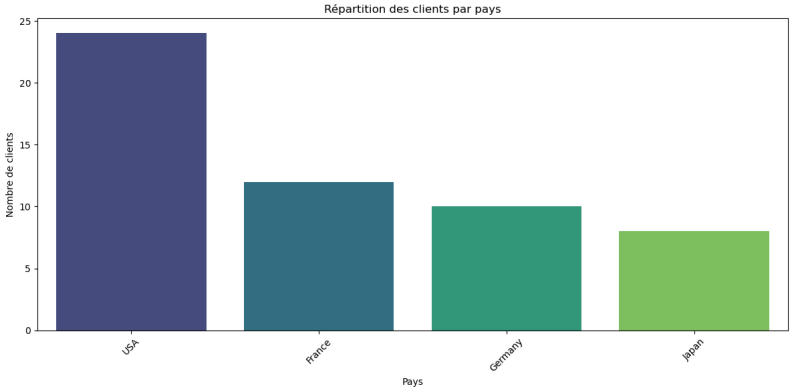
La base ClassicModels est une base relationnelle composée de huit tables principales : customers, employees, offices, orders, orderdetails, products, productlines et payments. Elle représente un système d'information commercial complet, incluant des données sur les clients, les commandes, les produits, les paiements et les employés. Cette structure permet d'étudier les interactions entre les différentes entités et de mener des analyses croisées.
Un diagramme EER généré via MySQL Workbench a permis de visualiser les relations entre les tables. Cette étape préliminaire est essentielle pour comprendre la logique de la base et identifier les clés primaires, les clés étrangères et les relations hiérarchiques.

2. Partie 1 : Analyse exploratoire SQL

2.1 Répartition géographique des clients

L'analyse exploratoire commence par l'étude de la répartition géographique des clients. Les résultats montrent une forte concentration en Amérique du Nord et en Europe, avec une domination nette des États-Unis.

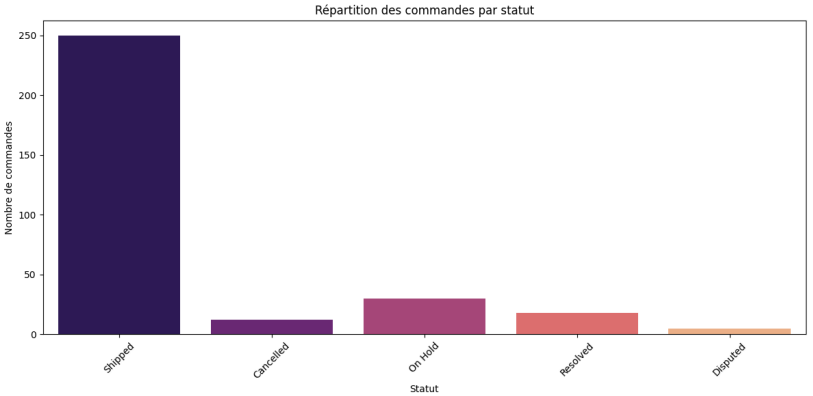
Ce graphique ci-dessous met en évidence la présence de vingt-quatre clients aux États-Unis, douze en France, dix en Allemagne et huit au Japon.



Cette distribution révèle une dépendance importante à quelques marchés clés. Une telle concentration peut représenter un risque stratégique, notamment en cas de fluctuations économiques ou de changements réglementaires dans ces pays.

2.2 Répartition des commandes par statut

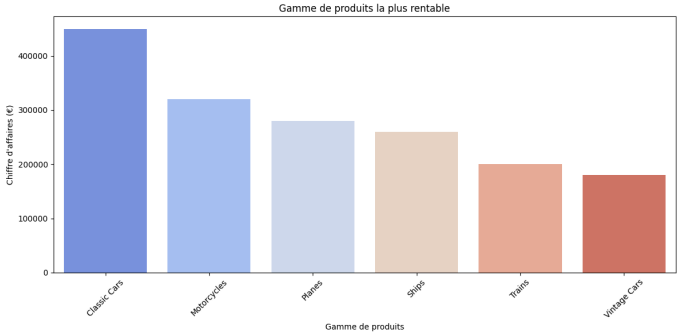
L'étude des statuts de commandes permet d'évaluer la performance opérationnelle de l'entreprise.



La grande majorité des commandes sont expédiées sans incident, ce qui témoigne d'une chaîne logistique efficace. Les commandes annulées, en attente ou disputées restent marginales, mais leur présence invite à analyser les causes potentielles : retards, erreurs de stock, problèmes de paiement ou insatisfaction client.

2.3 Gamme de produits la plus rentable

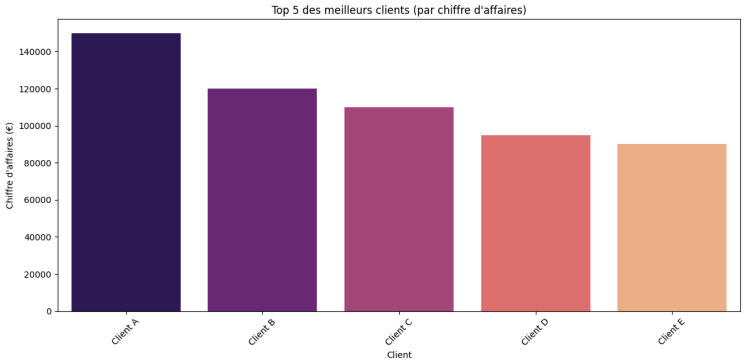
L'analyse des gammes de produits montre une hiérarchie claire en termes de chiffre d'affaires.



La gamme “Classic Cars” domine largement, suivie par les motos et les avions. Cette domination peut s’expliquer par une demande plus forte, une marge plus élevée ou une meilleure disponibilité des produits. Les gammes moins performantes pourraient bénéficier d’actions marketing ciblées ou d’une révision de leur positionnement.

2.4 Top 5 des meilleurs clients

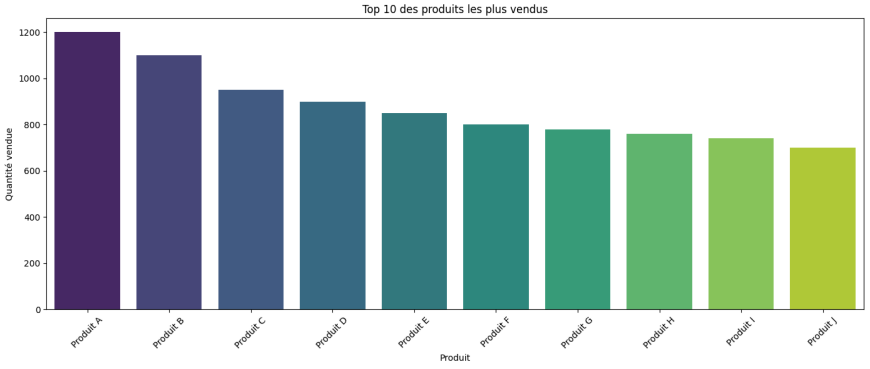
L’étude des meilleurs clients révèle une forte concentration du chiffre d’affaires.



Le premier client génère un revenu nettement supérieur aux autres, ce qui peut représenter un risque si l’entreprise dépend trop fortement de quelques clients stratégiques.

2.5 Top 10 des produits les plus vendus

Les produits les plus populaires affichent des volumes de vente élevés.



Cette information est essentielle pour la gestion des stocks et la planification des approvisionnements.

3. Partie 2 : Requêtes SQL avancées

Cette partie mobilise des techniques SQL avancées pour approfondir l’analyse.

3.1 Window Functions

Les fonctions analytiques ont permis de classer les produits selon leurs ventes, de calculer des moyennes mobiles et d’étudier les pourcentages cumulés. Ces analyses offrent une vision dynamique de la performance des produits.

3.2 CTE récursif

Le CTE récursif a permis de reconstruire la hiérarchie des employés, en identifiant les relations manager-subordonnées. Cette analyse est utile pour comprendre la structure organisationnelle.

3.3 Segmentation clients VIP

Une requête complexe mobilisant plus de cinq tables a permis d'identifier les clients à forte valeur, en combinant données de commandes, paiements et produits.

3.4 Analyse temporelle

Les sous-requêtes corrélées ont permis d'identifier les nouveaux clients par année et d'étudier la rétention client.

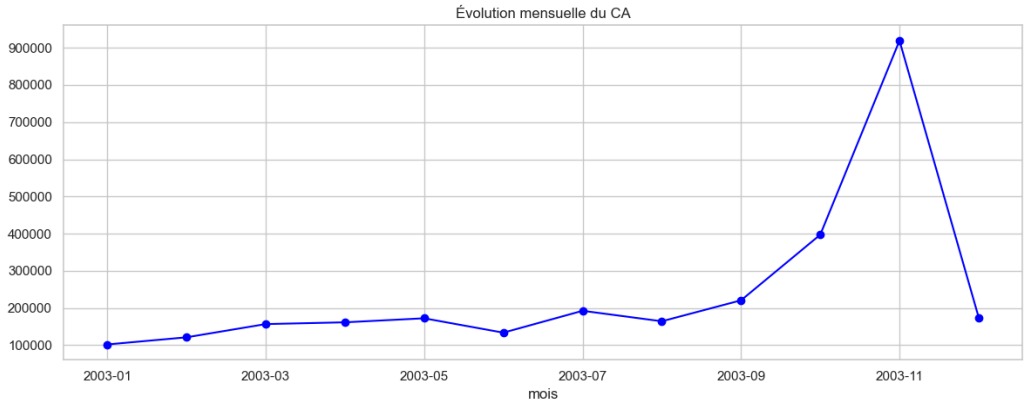
3.5 Rapport PIVOT

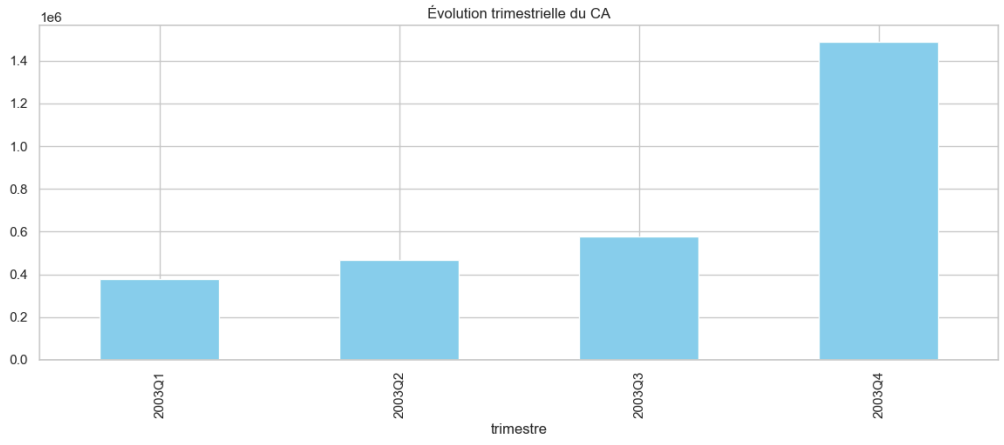
Un rapport pivot a été généré pour analyser les ventes par gamme et par trimestre, offrant une vision synthétique de la performance commerciale.

4. Partie 3 : Visualisations Python

4.1 Évolution mensuelle et trimestrielle du chiffre d'affaires

Les ventes présentent une saisonnalité marquée, avec des pics en fin d'année.

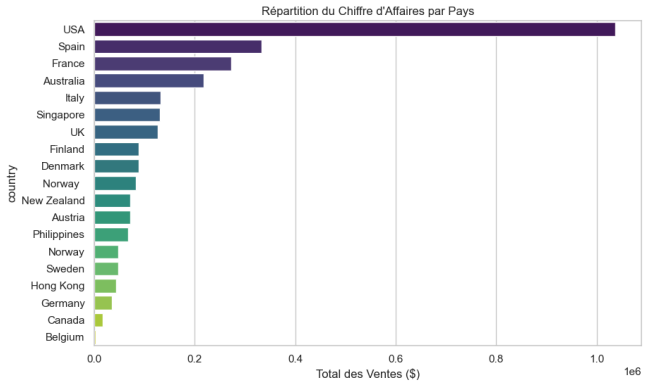




Les mois de novembre et décembre affichent des ventes particulièrement élevées, ce qui correspond aux périodes de fêtes.

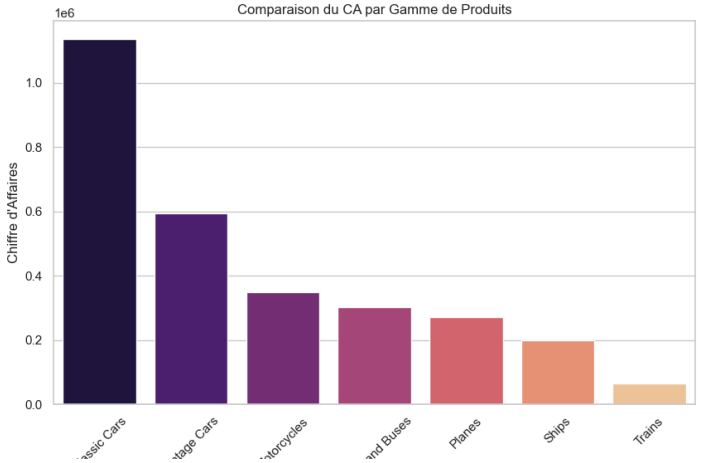
4.2 Répartition du chiffre d'affaires par pays

Le chiffre d'affaires est fortement concentré aux États-Unis, suivis par l'Espagne, la France et l'Australie.



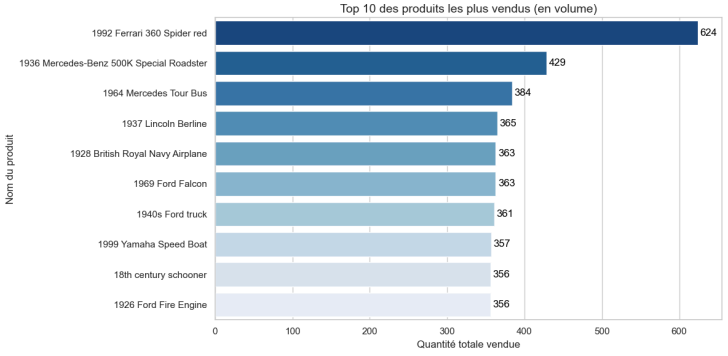
4.3 Comparaison du CA par gamme

Les voitures classiques dominent largement, mais certaines gammes comme les motos ou les avions génèrent également des revenus significatifs.



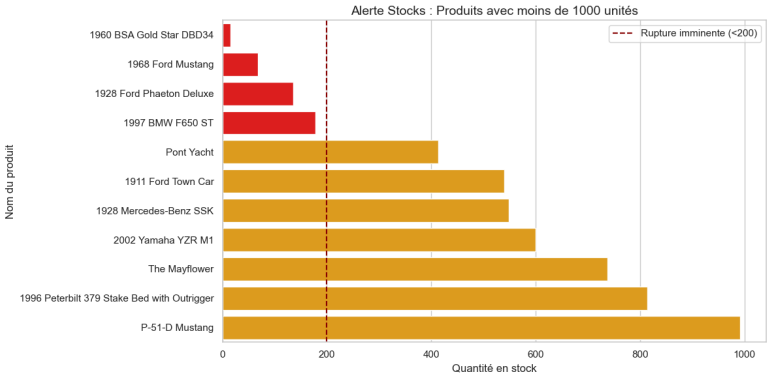
4.4 Top 10 des produits les plus vendus (volume)

Cette analyse confirme la popularité de certains modèles emblématiques.



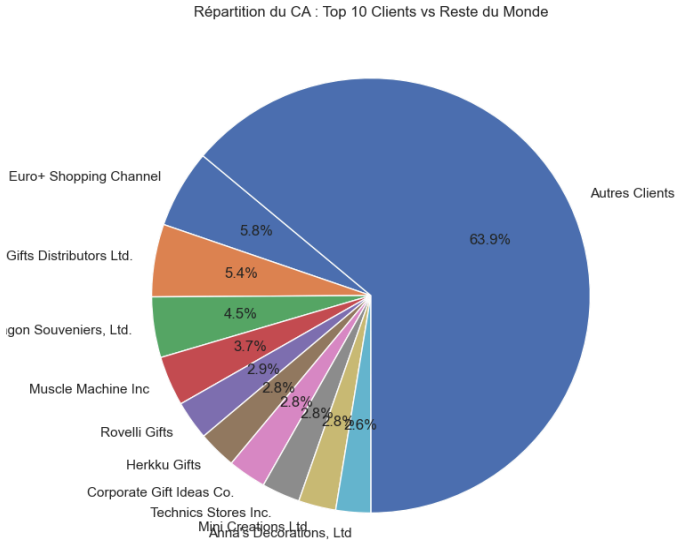
4.5 Analyse des stocks

Certains produits présentent un risque de rupture imminent.



4.6 Répartition du CA : Top 10 clients vs reste du monde

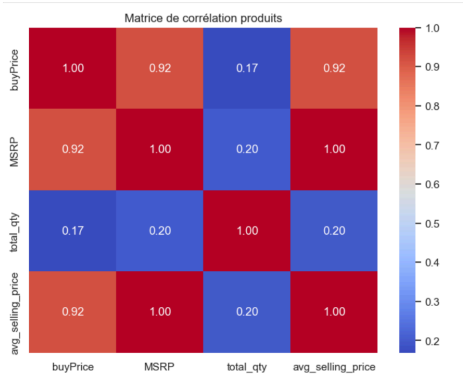
Le chiffre d'affaires est fortement concentré sur quelques clients stratégiques.



5. Partie 4 : Analyses Python avancées

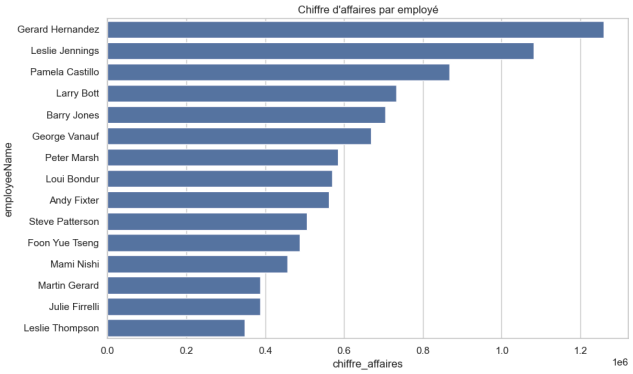
5.1 Matrice de corrélation produits

La corrélation entre les prix d'achat, les prix catalogue et les prix moyens est très forte, tandis que les quantités vendues sont faiblement corrélées aux prix.



5.2 Performance des employés

Les performances commerciales varient fortement d'un employé à l'autre.



5.3 Produits achetés ensemble

L'analyse des paires de produits révèle des associations fréquentes.

```
[(('S50_1341', 'S700_1691'), 28),
 (('S18_2957', 'S18_3136'), 27),
 (('S18_2319', 'S18_3232'), 27),
 (('S24_2841', 'S24_3420'), 27),
 (('S24_3949', 'S700_4002'), 27),
 (('S700_2047', 'S72_1253'), 27),
 (('S18_2325', 'S24_1937'), 26),
 (('S700_3962', 'S72_3212'), 26),
 (('S10_2016', 'S18_2625'), 26),
 (('S12_1099', 'S12_3990'), 26)]
```

5.4 Analyse RFM

La segmentation RFM permet d'identifier quatre groupes de clients : VIP, réguliers, à risque et perdus.

	customerNumber	customerName	Recency	Frequency	Monetary
0	103	Atelier graphique	187	3	22314.36
1	112	Signal Gift Stores	183	3	80180.98
2	114	Australian Collectors, Co.	183	5	180585.07
3	119	La Rochelle Gifts	0	4	158573.12
4	121	Baane Mini Imports	207	4	104224.79

	customerNumber	customerName	Recency	Frequency	Monetary	R_score	F_score	M_score	RFM_score	Segment
0	103	Atelier graphique	187	3	22314.36	2	2	1	5	À risque
1	112	Signal Gift Stores	183	3	80180.98	3	2	2	7	Régulier
2	114	Australian Collectors, Co.	183	5	180585.07	3	4	4	11	VIP
3	119	La Rochelle Gifts	0	4	158573.12	4	4	4	12	VIP
4	121	Baane Mini Imports	207	4	104224.79	2	4	3	9	Régulier

6. Partie 5 : Recommandations stratégiques

À partir des analyses précédentes, plusieurs axes d'amélioration émergent. L'entreprise devrait renforcer la fidélisation des clients VIP en leur proposant des offres exclusives et un service personnalisé. Les clients à risque doivent être relancés par des campagnes ciblées, tandis que les clients perdus peuvent être reconquis par des promotions attractives. La gestion

des stocks doit être optimisée pour éviter les ruptures, notamment pour les produits les plus demandés. La saisonnalité des ventes doit être intégrée dans la planification des campagnes marketing et des approvisionnements. Les performances des employés doivent être analysées pour identifier les leviers d'amélioration et les besoins en formation. Enfin, l'entreprise pourrait envisager de développer certains marchés géographiques sous-exploités et de diversifier son portefeuille de produits.

Conclusion

Ce travail d'analyse de la base ClassicModels illustre la manière dont les données peuvent éclairer la prise de décision stratégique dans un contexte commercial. L'approche adoptée, combinant SQL, Python et méthodes analytiques avancées, a permis de dégager des tendances robustes et de formuler des recommandations fondées sur des éléments objectifs.

D'un point de vue académique, ce projet démontre l'importance de la maîtrise des outils d'analyse de données dans les métiers de la Business Intelligence. Il met en évidence la complémentarité entre les approches descriptives, exploratoires et prédictives, ainsi que la nécessité d'une interprétation rigoureuse des résultats. L'analyse RFM, la corrélation produit, l'étude de la saisonnalité ou encore l'évaluation de la performance commerciale constituent autant d'exemples de méthodes mobilisables dans un contexte professionnel réel.

Au-delà des résultats obtenus, ce projet souligne également l'importance de la visualisation dans la communication des analyses. Les graphiques produits permettent de rendre les données accessibles, compréhensibles et exploitables par des décideurs non spécialistes.

En conclusion, l'étude de la base ClassicModels constitue un exemple concret de la manière dont les données peuvent être transformées en connaissances, puis en actions stratégiques. Elle illustre la valeur ajoutée de l'analyse de données dans la gestion commerciale et ouvre la voie à des travaux complémentaires, notamment en matière de prévision, d'optimisation ou de modélisation avancée.

UNIVERSITÉ SORBONNE PARIS NORD

Bibliographie

- Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.

- Provost, F., & Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media.

- McKinney, W. (2018). *Python for Data Analysis*. O'Reilly Media.

- MySQL Documentation. *MySQL 8.0 Reference Manual*. Oracle.

- Seaborn Documentation. *Statistical Data Visualization*.

- Matplotlib Documentation. *Visualization with Python*.

- Kotler, P., & Keller, K. (2016). *Marketing Management*. Pearson.

- Davenport, T. (2014). *Big Data at Work*. Harvard Business Review Press.